

# 1. Relations et dérivées de quelques fonction de base

#1. MQ  $\text{sigmoid}(x) = \frac{1}{2} (\tanh(\frac{x}{2}) + 1)$

$$\text{sigmoid}(x) = \frac{1}{2} (\tanh(\frac{x}{2}) + 1) \Leftrightarrow 2\text{sigmoid}(x) - 1 = \tanh(\frac{x}{2})$$

$$2\text{sigmoid}(x) - 1 = \frac{2 - 1 - \exp(-x)}{1 + \exp(-x)} = \frac{1 - \exp(-x)}{1 + \exp(-x)} = \frac{\exp(\frac{x}{2})}{\exp(\frac{x}{2})} \left( \frac{1 - \exp(-x)}{1 + \exp(-x)} \right)$$

$$= \frac{\exp(\frac{x}{2}) - \exp(\frac{x}{2})\exp(-x)}{\exp(\frac{x}{2}) + \exp(\frac{x}{2})\exp(-x)} = \frac{\exp(\frac{x}{2}) - \exp(-\frac{x}{2})}{\exp(\frac{x}{2}) + \exp(-\frac{x}{2})} = \tanh(\frac{x}{2})$$

#2. MQ  $\ln \text{sigmoid}(x) = \ln\left(\frac{1}{1 + \exp(-x)}\right) = -\ln(1 + \exp(-x)) = -\text{softplus}(-x)$

$$\ln \text{sigmoid}(x) = \ln\left(\frac{1}{1 + \exp(-x)}\right) = \ln(1) - \ln(1 + \exp(-x)) = 0 + \ln(1 + \exp(-x)) = -\text{softplus}(-x)$$

#3. MQ  $\frac{d \text{sigmoid}(x)}{dx} = \text{sigmoid}(x) (1 - \text{sigmoid}(x))$

$$\frac{d \text{sigmoid}(x)}{dx} = \frac{d((1 + \exp(-x))^{-1})}{dx} = \frac{-1}{(1 + e^{-x})^2} (-e^{-x}) = \left( \frac{1}{1 + e^{-x}} \right) \cdot \left( \frac{e^{-x}}{1 + e^{-x}} \right)$$

$$= \text{sigmoid}(x) \cdot \left( \frac{1 + e^{-x}}{1 + e^{-x}} - \frac{1}{1 + e^{-x}} \right) = \text{sigmoid}(x) \cdot (1 - \text{sigmoid}(x))$$

#4. MQ  $\tanh'(x) = 1 - \tanh^2(x)$

$$\frac{d}{dx} \left( \frac{e^x - e^{-x}}{e^x + e^{-x}} \right) = \frac{(e^x - e^{-x})'(e^x + e^{-x}) - (e^x - e^{-x})(e^x + e^{-x})'}{(e^x + e^{-x})^2} = \frac{(e^x + e^{-x})^2 - (e^x - e^{-x})^2}{(e^x + e^{-x})^2}$$

$$= \frac{(e^x + e^{-x})^2}{(e^x + e^{-x})^2} - \frac{(e^x - e^{-x})^2}{(e^x + e^{-x})^2} = 1 - \tanh^2(x)$$

#8.  $\|x\|_2^2 = \sum_i x_i^2$ . Ecrire  $\frac{\partial \|x\|_2^2}{\partial x}$

$$\frac{\partial \sum_i x_i^2}{\partial x} = \begin{pmatrix} \frac{\partial (x_1^2 + x_2^2 + \dots + x_n^2)}{\partial x_1} \\ \vdots \\ \frac{\partial (x_1^2 + x_2^2 + \dots + x_n^2)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} 2x_1 \\ 2x_2 \\ \vdots \\ 2x_n \end{pmatrix} = 2 \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = 2x$$

#9.  $\|x\|_1 = \sum_i |x_i|$ . Ecrire  $\frac{\partial \|x\|_1}{\partial x}$

$$\frac{\partial \sum_i |x_i|}{\partial x} = \begin{pmatrix} \frac{\partial (|x_1| + |x_2| + \dots + |x_n|)}{\partial x_1} \\ \vdots \\ \frac{\partial (|x_1| + |x_2| + \dots + |x_n|)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \text{sign}(x_1) \\ \text{sign}(x_2) \\ \vdots \\ \text{sign}(x_n) \end{pmatrix} = \text{sign}(x)$$

2. Calcul du gradient pour l'optimisation des paramètres d'un réseau de neurones pour la classification multiclasse



#1.  $W^{(1)}$   $d_h \times d$ , entre couche input et hidden.  $b^{(1)} \in \mathbb{R}^{d_h}$ ?

Donner la formule de calcul du vecteur de préactivations des neurones de la hidden layer  $h^a$  given  $x$  as input. first in a matrix form ( $h^a = \dots$ ). then how to compute one element ( $h_j^a = \dots$ ).

Écrire le vecteur des sorties des neurones de la hidden layer  $h^s$  en fonction de  $h^a$   
 $b^{(1)} \in \mathbb{R}^{d_h}$

$$h^a = b^{(1)} + W^{(1)} x$$

$$h^a = \begin{pmatrix} b_1^{(1)} \\ \vdots \\ b_{d_h}^{(1)} \end{pmatrix} + \begin{bmatrix} w_{11}^{(1)} & w_{12}^{(1)} & \dots & w_{1d}^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{d_h 1}^{(1)} & w_{d_h 2}^{(1)} & \dots & w_{d_h d}^{(1)} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} b_1^{(1)} + w_{11}^{(1)} x_1 + w_{12}^{(1)} x_2 + \dots + w_{1d}^{(1)} x_d \\ \vdots \\ b_{d_h}^{(1)} + w_{d_h 1}^{(1)} x_1 + w_{d_h 2}^{(1)} x_2 + \dots + w_{d_h d}^{(1)} x_d \end{bmatrix} \Rightarrow h_j^a = b_j^{(1)} + \sum_{i=1}^d w_{ji}^{(1)} x_i$$

$$h^s = \text{rect}(h^a)$$

#2 Donner dimension de  $W^{(2)}$  et  $b^{(2)}$  (entre hidden and output).

Donner la formule du vecteur d'activation des neurones de sortie  $o^a$  en fonction de  $h^s$ , puis  $o^a$

$W^{(2)}$  est  $m \times d_h$  et  $b^{(2)} \in \mathbb{R}^m$

$$o^a = b^{(2)} + W^{(2)} h^s$$

$$o^a = \begin{pmatrix} b_1^{(2)} \\ \vdots \\ b_m^{(2)} \end{pmatrix} + \begin{bmatrix} w_{11}^{(2)} & w_{12}^{(2)} & \dots & w_{1d_h}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{m1}^{(2)} & w_{m2}^{(2)} & \dots & w_{md_h}^{(2)} \end{bmatrix} \begin{bmatrix} h_1^s \\ \vdots \\ h_{d_h}^s \end{bmatrix} \Rightarrow o_k^a = b_k^{(2)} + \sum_{i=1}^{d_h} w_{ki}^{(2)} h_i^s$$

- #3. La sortie des neurones de sortie est  $O^s = \text{softmax}(O^a)$ . Préciser  $O_k^s$ .  
Démontrer que les  $O_k^s$  sont positifs et somment à 1. Pourquoi est-ce important?

$$O_k^s = \text{softmax}(O^a)_k = \frac{\exp(O_k^a)}{\sum_{i=1}^m \exp(O_i^a)}$$

Les  $O_k^s$  sont positifs par définitions de  $\exp(x)$  (i.e.  $\forall x \in \mathbb{R}, \exp(x) > 0$ ).

$$\sum_{k=1}^m O_k^s = \sum_{k=1}^m \frac{\exp(O_k^a)}{\sum_{i=1}^m \exp(O_i^a)} = \frac{\sum_{k=1}^m \exp(O_k^a)}{\sum_{i=1}^m \exp(O_i^a)} = 1$$

Il est important que les  $O_k^s$  soient positifs et qu'ils somment à 1, car cela permet d'interpréter  $O_k^s$  comme  $P(Y=k | X=x)$  (c'est-à-dire qu'on interprète  $O_k^s$  comme étant la probabilité que l'entrée  $x$  soit de la classe  $k$ ).

- #4.  $L(x, y) = -\log(O_y^s(x))$ . Préciser  $L$  en fonction de  $O^a$

$$\begin{aligned} L(x, y) &= -\log\left(\frac{\exp(O_y^a)}{\sum_{i=1}^m \exp(O_i^a)}\right) = \log\left(\sum_{i=1}^m \exp(O_i^a)\right) - \log(\exp(O_y^a)) \\ &= \log\left(\sum_{i=1}^m \exp(O_i^a)\right) - O_y^a \end{aligned}$$

- #5. Formuler  $\hat{R}$ . Indiquer précisément l'ensemble  $\Theta$  des paramètres du réseau. Indiquer à combien de paramètres scalaires  $n_\theta$  cela correspond. Formuler le problème d'optimisation qui correspond à l'entraînement du réseau pour trouver une valeur optimale des paramètres.

$$\hat{R} = \frac{1}{n} \sum_{i=1}^n L(x^{(i)}, y^{(i)}) = \frac{1}{n} \sum_{i=1}^n \left( \log\left(\sum_{j=1}^m \exp(O_j^a(x^{(i)}))\right) - O_{y^{(i)}}^a(x^{(i)}) \right)$$

$$\Theta = \{W^{(1)}, b^{(1)}, W^{(2)}, b^{(2)}\}$$

$$n_\theta = d_h \times d + d_h + m \times d_h + m$$

Le problème d'optimisation qui correspond à l'entraînement du réseau permettant de trouver une valeur optimale des paramètres est  $\arg\min_{\Theta} \hat{R}(\Theta, D_{\text{train}})$

#6. Exprimer avec un bref pseudo-code la descente de gradient pour ce problème

initialize  $\theta$

for  $N$  iterations:

$$\theta \leftarrow \theta - \eta \cdot \left( \frac{1}{n} \cdot \sum_{i=1}^n \frac{\partial}{\partial \theta} \left( \log \left( \sum_{j=1}^m \exp(o_j^a(x^{(i)})) \right) - o_{y^{(i)}}^a(x^{(i)}) \right) \right)$$

#7. MQ  $\frac{\partial L}{\partial o^a} = o^s - \text{onehot}_m(y)$

Pour  $k \neq y$ ,  $\frac{\partial L(x, y)}{\partial o_k^a} = \frac{\partial \left( \log \left( \sum_{j=1}^m \exp(o_j^a) \right) - o_y^a \right)}{\partial o_k^a} = \frac{\partial \log \left( \sum_{j=1}^m \exp(o_j^a) \right)}{\partial o_k^a}$

$$= \frac{1}{\sum_{j=1}^m \exp(o_j^a)} \cdot \frac{\partial \sum_{j=1}^m \exp(o_j^a)}{\partial o_k^a} = \frac{\exp(o_k^a)}{\sum_{j=1}^m \exp(o_j^a)} = o_k^s$$

$$\frac{\partial L(x, y)}{\partial o_y^a} = \frac{\partial \left( \log \left( \sum_{j=1}^m \exp(o_j^a) \right) - o_y^a \right)}{\partial o_y^a} = \frac{\exp(o_y^a)}{\sum_{j=1}^m \exp(o_j^a)} - 1 = o_y^s - 1$$

$$\text{Alors, } \frac{\partial L(x, y)}{\partial o^a} = \begin{pmatrix} \frac{\partial L}{\partial o_1^a} \\ \vdots \\ \frac{\partial L}{\partial o_m^a} \end{pmatrix} = \begin{pmatrix} o_1^s \\ \vdots \\ o_y^s \\ \vdots \\ o_m^s \end{pmatrix} - \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} = o^s - \text{onehot}_m(y)$$

#8. Donner l'expression correspondante en numpy

$$\text{grad\_oa} = o^s - \text{np.eye}(m)[y-1]$$

car  $y \in \{1, \dots, m\}$  et le vecteur  $\text{onehot}_m$  à des index de 0 à  $m-1$

#9. Calculer  $\frac{\partial L}{\partial W^{(2)}}$  et  $\frac{\partial L}{\partial b^{(2)}}$

Pour  $k \neq y$ ,  $\frac{\partial L(x,y)}{\partial W_{kj}^{(2)}} = o_k^s \cdot \frac{\partial o_k^s}{\partial W_{kj}^{(2)}} = o_k^s \cdot \frac{\partial (b_k^{(2)} + \sum_{i=1}^{d_h} W_{ki}^{(2)} h_i^s)}{\partial W_{kj}^{(2)}} = o_k^s \cdot h_j^s$

Pour  $k=y$ ,  $\frac{\partial L(x,y)}{\partial W_{yj}^{(2)}} = (o_y^s - 1) \cdot \frac{\partial o_y^s}{\partial W_{yj}^{(2)}} = (o_y^s - 1) \cdot h_j^s = o_y^s h_j^s - h_j^s$

Pour  $k \neq y$ ,  $\frac{\partial L(x,y)}{\partial b_k^{(2)}} = o_k^s \cdot \frac{\partial (b_k^{(2)} + \sum_{i=1}^{d_h} W_{ki}^{(2)} h_i^s)}{\partial b_k^{(2)}} = o_k^s$

Pour  $k=y$ ,  $\frac{\partial L(x,y)}{\partial b_y^{(2)}} = o_y^s - 1$

Alors,  $\frac{\partial L}{\partial W^{(2)}} = \begin{bmatrix} o_1^s h_1^s & o_1^s h_2^s & \dots & o_1^s h_{d_h}^s \\ \vdots & & & \vdots \\ o_m^s h_1^s & \dots & o_m^s h_{d_h}^s \end{bmatrix} - \begin{bmatrix} 0 & \dots & 0 \\ \vdots & & \vdots \\ h_1^s & h_2^s & \dots & h_{d_h}^s \\ \vdots & & & \vdots \\ 0 & \dots & 0 \end{bmatrix} \leftarrow \text{ligne } y$

$\frac{\partial L}{\partial b^{(2)}} = \begin{pmatrix} o_1^s \\ o_2^s \\ \vdots \\ o_y^s \\ \vdots \\ o_m^s \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ \vdots \\ 0 \end{pmatrix} = O^s - \text{onehot}_m(y)$

#10 Donner les expressions correspondantes en numpy

$\text{grad\_b2} = O^s - \text{np.eye}(m)[y-1]$

$\text{grad\_W2} = \text{np.outer}(O^s, h^s) - \text{np.concatenate}((\text{np.zeros}((y-1, d_h))), h^s.\text{reshape}(1, d_h), \text{np.zeros}((m-y, d_h)))$

$\text{grad\_b2}$  est  $m \times 1$

$\text{grad\_W2}$  est  $m \times d_h$

Car  $\frac{\partial L}{\partial b^{(2)}} = O^s - \text{onehot}_m(y)$  et  $\frac{\partial L}{\partial W^{(2)}} = O^s h^{sT} - \begin{bmatrix} 0 & 0 & \dots & 0 \\ \vdots & & & \vdots \\ h_1^s & h_2^s & \dots & h_{d_h}^s \\ \vdots & & & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \leftarrow \text{ligne } y$

où  $O^s$  et  $\text{onehot}_m(y)$  sont  $m \times 1$ ,  $h^s$  est  $d_h \times 1$  et la matrice contenant que des zeros et les éléments de  $h^s$  est  $m \times d_h$

#11. Calculer  $\frac{\partial L}{\partial h^s}$

$$\frac{\partial L}{\partial h_j^s} = \sum_{k=1}^m \frac{\partial L}{\partial o_k^a} \cdot \frac{\partial o_k^a}{\partial h_j^s} = \sum_{k=1}^m \frac{\partial L}{\partial o_k^a} \cdot \frac{\partial (b^{(2)} + \sum_{i=1}^{d_h} W_{ki}^{(2)} h_i^s)}{\partial h_j^s}$$

$$= \sum_{k=1}^m \frac{\partial L}{\partial o_k^a} \cdot W_{kj}^{(2)} = o_1^s W_{1j}^{(2)} + o_2^s W_{2j}^{(2)} + \dots + (o_y^s - 1) W_{yj}^{(2)} + \dots + o_m^s W_{mj}^{(2)}$$

$$= \sum_{k=1}^m o_k^s W_{kj}^{(2)} - W_{yj}^{(2)}$$

$$\text{Alors, } \frac{\partial L}{\partial h^s} = \begin{pmatrix} \sum_{k=1}^m o_k^s W_{k1}^{(2)} - W_{y1}^{(2)} \\ \sum_{k=1}^m o_k^s W_{k2}^{(2)} - W_{y2}^{(2)} \\ \dots \\ \sum_{k=1}^m o_k^s W_{kd_h}^{(2)} - W_{yd_h}^{(2)} \end{pmatrix}$$

#12. Exprimer sous forme matricielle, Préciser les dimensions, en numpy grad-hs = ?

$$\frac{\partial L}{\partial h^s} = W^{(2)T} \cdot o^s - W^{(2)}[y, :]^T$$

où  $W^{(2)T}$  est  $d_h \times m$ ,  $o^s$  est  $m \times 1$  et  $W^{(2)}[y, :]^T$  est  $d_h \times 1$

$$\text{grad-hs} = W2^T \cdot os - W2[y-1, :]^T$$

#13. Calculer  $\frac{\partial L}{\partial h^a}$

$$\frac{\partial L}{\partial h_j^a} = \frac{\partial L}{\partial h_j^s} \cdot \frac{\partial h_j^s}{\partial h_j^a} = \left( \sum_{k=1}^m o_k^s w_{kj}^{(2)} - w_{y_j}^{(2)} \right) \cdot \frac{\partial (\text{rect}(h_j^a))}{\partial h_j^a} = \left( \sum_{k=1}^m o_k^s w_{kj}^{(2)} - w_{y_j}^{(2)} \right) \mathbb{1}_{\{h_j^a > 0\}}(h_j^a)$$

$$\text{Alors, } \frac{\partial L}{\partial h^a} = \begin{pmatrix} \left( \sum_{k=1}^m o_k^s w_{k1}^{(2)} - w_{y_1}^{(2)} \right) \mathbb{1}_{\{h_1^a > 0\}}(h_1^a) \\ \vdots \\ \left( \sum_{k=1}^m o_k^s w_{kd_h}^{(2)} - w_{y_{d_h}}^{(2)} \right) \mathbb{1}_{\{h_{d_h}^a > 0\}}(h_{d_h}^a) \end{pmatrix}$$

#14. Exprimer sous forme matricielle, Préciser les informations, donner l'équivalent <sup>en</sup> numpy

$$\frac{\partial L}{\partial h^a} = \left( \frac{\partial L}{\partial h^s} \right) \odot \begin{pmatrix} \mathbb{1}_{\{h_1^a > 0\}}(h_1^a) \\ \vdots \\ \mathbb{1}_{\{h_{d_h}^a > 0\}}(h_{d_h}^a) \end{pmatrix}$$

où  $\frac{\partial L}{\partial h^a}$ ,  $\frac{\partial L}{\partial h^s}$  et le vecteur contenant les fonctions indicatrices sont  $d_h \times 1$

`vector_indicator = np.array([1 if e > 0 else 0 for e in hs])`

`grad_ha = np.multiply(grad_hs, vector_indicator)`



#15. Calculer  $\frac{\partial L}{\partial W^{(1)}}$  et  $\frac{\partial L}{\partial b^{(1)}}$

$$\frac{\partial L}{\partial W_{jl}^{(1)}} = \frac{\partial L}{\partial h_j^a} \cdot \frac{\partial h_j^a}{\partial W_{jl}^{(1)}} = (\sum_{k=1}^m O_k^s W_{kj}^{(2)} - W_{yj}^{(2)}) \mathbb{1}_{\{h_j^a > 0\}}(h_j^a) \cdot \frac{\partial (b_j^{(1)} + \sum_{i=1}^d W_{ji}^{(1)} x_i)}{\partial W_{jl}^{(1)}}$$

$$= (\sum_{k=1}^m O_k^s W_{kj}^{(2)} - W_{yj}^{(2)}) \mathbb{1}_{\{h_j^a > 0\}}(h_j^a) x_l = \frac{\partial L}{\partial h_j^a} \cdot x_l$$

$$\frac{\partial L}{\partial b_j^{(1)}} = \frac{\partial L}{\partial h_j^a} \cdot \frac{\partial h_j^a}{\partial b_j^{(1)}} = \frac{\partial L}{\partial h_j^a} \cdot 1 = \frac{\partial L}{\partial h_j^a}$$

$$\frac{\partial L}{\partial W^{(1)}} = \begin{bmatrix} \frac{\partial L}{\partial h_1^a} \cdot x_1 & \frac{\partial L}{\partial h_1^a} \cdot x_2 & \dots & \frac{\partial L}{\partial h_1^a} \cdot x_d \\ \frac{\partial L}{\partial h_2^a} \cdot x_1 & \frac{\partial L}{\partial h_2^a} \cdot x_2 & \dots & \frac{\partial L}{\partial h_2^a} \cdot x_d \\ \dots & \dots & \dots & \dots \\ \frac{\partial L}{\partial h_{d_h}^a} \cdot x_1 & \frac{\partial L}{\partial h_{d_h}^a} \cdot x_2 & \dots & \frac{\partial L}{\partial h_{d_h}^a} \cdot x_d \end{bmatrix}$$

$$\frac{\partial L}{\partial b^{(1)}} = \frac{\partial L}{\partial h^a}$$

#16. Exprimer sous forme matricielle, définir les dimensions, donner l'équivalent en numpy

$$\frac{\partial L}{\partial b^{(1)}} = \frac{\partial L}{\partial h^a} \text{ est } d_h \times 1$$

$$\frac{\partial L}{\partial W^{(1)}} = \frac{\partial L}{\partial h^a} \cdot x^T \text{ est } d_h \times d \text{ car } \frac{\partial L}{\partial h^a} \text{ est } d_h \times 1 \text{ et } x^T \text{ est } 1 \times d$$

$$\text{grad\_b1} = \text{grad\_ha}$$

$$\text{grad\_W1} = \text{np.outer}(\text{grad\_ha}, x)$$

